AI Humanizer技术调研和总结

1. 研究概况

(Meng et al. 2025)对AI Detector和AI Humanizer的源流和分类做了系统的综述，概要如下：

Detector分类

Detector分为事后（post-hoc）和主动（proactive）两类。

事后检测器

事后检测器又分为深度学习检测器和统计检测器。

深度学习检测器

- **定义**：通过微调语言模型（LM）得到的二分类器
- **特点**：简单有效，但需要大量训练数据
- **代表方法**：
  - CheckGPT（冻结LM，增加BiLSTM头）
  - MPU（多尺度模块和PU损失，提升短文本检测）
  - DEMASQ（基于能量模型）
- **优势**：准确率高
- **劣势**：需大数据

统计检测器

- **代表方法**：
  - GLTR（跟踪每个token概率）
  - DetectGPT（扰动文本后比较困惑度变化）
- **优势**：适合小样本场景

主动检测器

需要修改大模型推理过程，通常由服务商维护并提供API

水印法

- **原理**：在生成时嵌入不可见水印，检测时测量水印强度
- **代表方法**：KGW方法
- **优点**：检测原理稳健
- **缺点**：影响文本质量，易被同义改写攻击破解

检索法

- **原理**：将历史生成文本存库，检测时比对
- **缺点**：涉及用户数据存储，存在隐私和合规风险，存储量巨大

Humanizer分类

Humanizer分为基于扰动（perturbation-based）和基于释义（paraphrase-based）两类。

基于扰动（Perturbation-based）

- **特点**：通过替换文本中的特定词语来逃避检测
- **缺点**：会降低文本流畅性和可读性
- **代表方法**：
  - RP（用同义词随机替换词语）
  - DFTFooler（利用AIGT困惑度低的特点，替换语言模型最有信心的前N个词）
  - TextFooler（通过查询检测器找出重要词并替换）

基于释义（Paraphrase-based）

- **特点**：通过释义重写文本，改变表达但不改变含义
- **缺点**：难以精确控制修改幅度，调节选项有限
- **代表方法**：
  - DIPPER（大规模seq2seq模型，能控制词汇和顺序多样性）
  - SentPara（逐句释义后重组，模型参数远小于DIPPER）

2. 工作归纳

文献调研发现最近比较好的工作都是基于**微调语言模型的Detector**和**基于释义的Humanizer**，下面分别介绍。其中开源的方法大都不适用，最新的且比较好的适用的方法都需要自己根据论文来写算法。

2.1 自定义损失函数的对抗方法

论文：GradEscape(Meng et al. 2025)（开源）

2.1.1 模型配置

- **模型大小**：T5-139M
- **硬件配置**：2 × A100-80GB GPU节点，32个CPU核心，1TB内存

2.1.2 数据集

- GROVER News
- HC3
- GPA
- GPTWiki Intro

2.1.3 评测的检测器

微调模型： - RoBERTa - GPT2 - BERT
专用检测器： - MPU - CheckGPT
统计方法： - GLTR

2.1.4 基准Humanizer

基于扰动： - RP - DFTFooler
基于释义： - DIPPER - SentPara

2.1.5 评价指标

逃避效果： - Evasion Rate
文本质量： - ROUGE - Cos-sim - Perplexity - GRUEN

2.1.6 核心方法

用以下损失函数训练一个深度学习Paraphraser:

$$min \quad L_{DV} F_\theta x_{ii=1} n, y_{human}$$

$$s.t. \quad dis_{syn} F_\theta x_{ii=1} n, x_{ii=1} n < T_{syn}$$

$$dis_{sem} F_\theta x_{ii=1} n, x_{ii=1} n < T_{sem}$$

符号说明：

- F_θ ： 最终要训练得到的Paraphraser
- L_{DV} ： 检测器 D_V 的交叉熵损失
- dis_{syn} 和 dis_{sem} ： 分别测量输入和输出之间的句法距离和语义距离
- T_{syn} 和 T_{sem} ： 分别表示句法阈值和语义阈值

约束作用：

- T_{syn} ： 限制 F_θ 可以改变文本结构的程度
- T_{sem} ： 确保 F_θ 不会显著改变文本的含义

2.1.7 优缺点分析

✓ 优点：

- 不需要提供人类文本，直接用AI文本即可

✗ 挑战：

- 需要 L_{DV} 是开源的
- 对于黑盒模型需要使用模型窃取技术探查得到Tokenizer和推断模型结果，然后重新训练替代模型，这本身就很困难

2.2 强化学习方法（DPO）

论文：LANGUAGE MODEL DETECTORS ARE EASILY OPTIMIZED AGAINST(Nicks et al. 2023)（开源）

2.2.1 模型配置

- **模型大小**：7B parameter Llama-2-base model

2.2.2 数据集

使用Llama-2-7B对以下数据集生成样本，构建偏好数据集

- OpenWebText
- Alpaca instruction dataset
- 人写的文章标题
- Writing Prompts dataset

2.2.3 评测的检测器

微调模型： - RoBERTa-large - RoBERTa-base
Zero-shot统计： - Log Rank - Log Probability
Zero-shot扰动： - DetectGPT - DetectLLM
商业检测器： - GPTZero - Sapling - Originality.ai (model 2.0) - Winston AI

2.2.4 基准Humanizer

N/A

2.2.5 评价指标

检测性能： - AUROC
文本质量： - Perplexity - GPT4 win rate - Offline entropy

2.2.6 核心方法

使用DPO对Llama-2-7B进行微调

2.2.7 优缺点分析

✗ 缺点：

- 本质上是用有监督分类方法训练一个Detector

2.3 有监督微调方法

论文：Dipper(Krishna et al. 2023)（开源）

2.3.1 模型配置

- **模型大小**：T5-XXL 11B

2.3.2 数据集

训练数据： - PAR3 dataset构建对齐数据
测试数据： - GPT2-XL (1.5B) 生成300 tokens - OPT-13B 生成300 tokens - text-davinci-003 生成300 tokens - WikiText-103的验证集采样3K个两句话的块+接下来300 tokens（人类文本）

2.3.3 评测的检测器

水印检测： - Watermarking
统计方法： - DetectGPT
商业检测器： - GPTZero - OpenAI’s text classifier
排序方法： - RankGenXL-all

2.3.4 基准Humanizer

N/A

2.3.5 评价指标

检测性能： - Detection Accuracy
语义保持： - Semantic similarity

2.3.6 核心方法

- 人工构造对齐数据
- 使用SFT方式让模型学会如何paraphrase

2.4 强化学习方法（PPO）

论文：Radar(Hu et al. 2023)（闭源）

2.4.1 模型配置

- **模型**：T5-large和RoBERTa-large分别作为paraphraser和detector的初始化
- **硬件配置**：2 GPUs (NVIDIA Tesla V100 32GB)

2.4.2 数据集

使用Pythia-2.8B - Dolly-V2-3B - Palmyra-base - Camel-5B - GPT-J-6B - Dolly-V1-6B - LLaMA-7B - Vicuna-7B对以下人类文本生成ai文本
训练人类文本： - WebText采样160K文档
测试人类文本： - Xsum - SQuAD - Reddit WritingPrompts (WP) - TOEFL

2.4.3 评测的检测器

微调模型： - OpenAI (RoBERTa) model
统计方法： - Log probability - Rank - Log rank - Entropy - DetectGPT

2.4.4 基准Humanizer

N/A

2.4.5 评价指标

检测性能： - AUROC
文本质量： - GPT-3.5-Turbo评分 - Quora Question Pairs - iBLEU

2.4.6 核心方法

训练流程包括以下步骤：
1. 使用要攻击的AI模型对人类文本做生成形成AI文本
2. 使用paraphraser对AI文本做转移形成转义文本
3. 使用detector对转义文本打分
4. 使用PPO和打分更新phraser
5. 使用人类文本、AI文本和转义文本更新detector

2.4.7 优缺点分析

✗ 缺点：
- 官方没有release训练代码和数据，只有detector的checkpoint

3. Detector / Humanizer API (by Abdellah)

Detectors	Website of the paper or api	Usage demo	Pricing plan, if available
DetectGPT	https://detectgpt.com		Essential 15$/mo Pro 29$/mo

	/app/ https://arxiv.org/pdf/2301.11305		Business 59$/mo
GPTZero	https://gptzero.me/ https://app.gptzero.me/api-subscription	Create an account at https://app.gptzero.me Sign up for an API subscription plan at https://app.gptzero.me/app/api-subscription Get your API key at https://app.gptzero.me/app/api Visit the API docs to get ready-to-use code to call the API : headers = { 'x-api-key': "", 'Content-Type': "application/json", 'Accept': "application/json" }	300k words/mo : 45$/mo 1m words/mo : 135$/mo 2m words/mo : 250$/mo 5m words/mo : 550$/mo 10m words/mo : 1000$/mo 20m words/mo : 1850$/mo
Originality AI Lite	https://originality.ai/	Create or Login to Originality.ai and subscribe to Enterprise level plan	• $136.58 /month • 15,000 credits (renews monthly) where 1 credits equal to 100 words

		Create an api key for use here: https://app.originality.ai/home/api-token-dashboard Prepare Requests: All requests must contain the following header: headers = { 'X-OAI-API-KEY': 'your-api-key',}	• The rate limit for our api is 500 requests per minute. Your remaining limit for the current minute can be found by examining the response headers after a request has completed. In the event you have reached the upper limit, a 429 “too many requests” error will be returned by our system

Winston AI	https://gowinston.ai/	Create an api key for use here: https://dev.gowinston.ai/user/api-tokens
		Prepare Requests: All requests must contain the following header: headers = { "Authorization": "Bearer <token>", "Content-Type": "application/json"}
			• winstonai的api是35美元500000credit, 60美元1000000credit, 150美元3000000credit, 200美元5000000credit, 300美元一千万credit, 400美元二千万credit.
			• The credit cost per word depends on the endpoint
			  ◦ AI content detection: 1 credit per word
			  ◦ Plagiarism detection: 2 credits per word
			  ◦ Fact Checker : 2 credits per word
			  ◦ AI image detection: 300 credits per image
			  ◦ Text compare: 1/2 credit per total words found in both texts
			• up to 100,000 characters per scan and unlimited per hour.

ZeroGPT	https://www.zerogpt.com/	Create an api key for use: https://app.theneo.io/olive-works-llc/zerogpt-docs/detect Prepare Requests: All requests must contain the following header: headers = {	Pro : 7.99$/mo Plus : 14.99$/mo Max : 18.99$/mo Expert : 69.99$/mo ENTREPRISE: Get a custom quote based on your needs API Business Plans (Pay as you go): Beginner: $0.034 /1000 Words Pro: $0.049 /1000 Words VIP: $0.069 /1000 Words

		'ApiKey': 'Generate your api key, and paste it here',}	
grammarly	https://www.grammarly.com/	Contact Enterprise Sales team	Pro: 12$/mo Entreprise: Contact sales
QuillBot	https://quillbot.com/	Quillbot no longer has an API	
AI Detector Pro	https://aidetector.pro/	needs subscreption first	49.99$/mo

参考文献

Hu, Xiaomeng, Pin-Yu Chen, and Tsung-Yi Ho. 2023. *RADAR: Robust AI-Text Detection via Adversarial Learning*. arXiv:2307.03838. arXiv. https://doi.org/10.48550/arXiv.2307.03838.

Krishna, Kalpesh, Yixiao Song, Marzena Karpinska, John Wieting, and Mohit Iyyer. 2023. *Paraphrasing Evades Detectors of AI-generated Text, but Retrieval Is an Effective Defense*. arXiv:2303.13408. arXiv. https://doi.org/10.48550/arXiv.2303.13408.

Meng, Wenlong, Shuguo Fan, Chengkun Wei, et al. 2025. *GradEscape: A Gradient-Based Evader Against AI-Generated Text Detectors*. arXiv:2506.08188. arXiv. https://doi.org/10.48550/arXiv.2506.08188.

Nicks, Charlotte, Eric Mitchell, Rafael Rafailov, et al. 2023. "Language Model Detectors Are Easily Optimized Against." *The Twelfth International Conference on Learning Representations*, October.